

引擎接地的调度诊断解释层：LLM 在 FJSP+MAPF 耦合系统中的 定位、归因与可验证干预

SkyResearch

2026 年 9 月 1 日 v1 草稿（设计 + 基线，LLM 推理待配置）

摘要

FJSP+MAPF 耦合系统产生丰富的运行工件（指标轨迹、扰动事件流、计划修订账本、异常日志），但缺少把它们变成可理解因果叙述的层。本文提出 **引擎接地的 LLM 诊断层**：（1）形式化调度诊断任务 $\mathcal{D} : (\tau, q) \mapsto e$ ——给定轨迹 τ 与查询 q ，产出解释 $e = (\text{定位}, \text{归因}, \text{证据}, \text{干预})$ ；（2）三个设计支柱：结构化证据打包（引擎工件 $\rightarrow$ 紧凑上下文）、接地约束（解释中的每个证据可回查日志）、反事实验证（推荐干预在引擎中重仿真， ΔKPI 即为干预效果的客观评分——LLM 不被允许“讲故事”）；（3）诊断案例数据集：以已知注入扰动为 ground truth 的 (τ, e^*) 对，支持定位准确率/干预成功率/忠实度的定量评测；（4）实现规则基线诊断器与 LLM 提示模板，LLM 推理接口留待配置后一键评测。与 LLM-CO 工作（HeurAgenix、CO-Bench 生成启发式）不同，本层是事后诊断且可被引擎证伪。

1 引言

姊妹篇们把耦合系统当作被优化对象；本篇把它当作被解释对象。动机：车间运维人员面对的不是一个最优解，而是“为什么这批单晚了/为什么 AGV 都在等”——这需要把指标轨迹、事件流与计划演变合成因果叙述。LLM 恰好擅长叙述合成，但其可信性需要**接地**（grounding）：证据可回查、判断可验证。

三个社区现状：LLM-CO（HeurAgenix[1]、CO-Bench[2]）用 LLM 设计启发式/搜索法——生成侧、无引擎验证闭环；XAI-for-scheduling 集中在特征归因而非事件级因果；SkyEngine 已有丰富的审计工件（修订账本、异常日志、指标枢纽）但无人消费它们。

2 诊断任务形式化

定义 1 (轨迹). $\tau = (\mathbf{m}_{0:T}, \mathbf{e}_{0:T}, \mathbf{r}_{0:T}, \Sigma)$: 指标轨迹 $\mathbf{m}$ (每 w 步的 KPI 向量)、事件流 $\mathbf{e}$ (扰动/恢复/冲突)、计划修订账本 $\mathbf{r}$ 、episode 汇总 Σ 。

定义 2 (诊断). $\mathcal{D} : (\tau, q) \mapsto e$, 其中查询 q 如 “makespan 为何超预期” “哪台资源是瓶颈”; 解释 $e = (\ell, h, V, \iota)$: 定位 ℓ (资源/区域/时段)、归因假设 h (原因类别: 扰动/拥堵/饥饿/计划失配/参数失当)、证据 $V \subseteq \tau$ (可回查的索引集合)、干预 ι (参数/策略/配置的具体修改建议)。

评测 (ground truth 来自受控注入):

$$\text{定位准确率} = \Pr[\ell = \ell^*], \quad \text{归因准确率} = \Pr[h = h^*], \quad (1)$$

$$\text{干预成功率} = \Pr[\text{KPI}(\text{re-sim}(\iota)) \geq \text{KPI}(\tau) + \delta], \quad (2)$$

$$\text{忠实度} = \Pr[\text{每条证据可回查且语义一致}]. \quad (3)$$

反事实验证是核心: 干预建议在引擎中重仿真取得 ΔKPI , LLM 的叙述质量被客观化。

3 架构

1. **证据打包器**: $\tau \rightarrow$ 紧凑上下文 (KPI 轨迹分段摘要、事件时间线、修订统计、拓扑摘要), 预算约 4-8k token;
2. **诊断策略**: 规则基线 (阈值 + 峰值定位) / LLM (提示模板含接地约束: “仅引用给定证据 ID” “干预必须可在配置中落地”) / 混合 (规则出候选、LLM 排序叙述);
3. **反事实执行器**: 对 ι 修改配置重仿真 (引擎确定性保证公平对比), 产出 ΔKPI 回填为训练/评测信号——可进一步做 DPO 式的自我改进闭环。

4 案例数据集与基线 (本篇已交付部分)

构建: 复用方向 1 的扰动试点 (已知 ℓ^*, h^*) + 方向 2 的失稳案例 (饥饿型活锁, ground truth = 任务池无人接单), 每案例打包为 JSON (轨迹摘要 + 事件 + 汇总 + ground truth)。**规则基线**: 峰值队列 $\rightarrow$ 机器定位; 阻塞延迟高 $\rightarrow$ 拥堵归因; AGV 空闲率高且任务池非空 $\rightarrow$ 饥饿归因; 修订账本激增 $\rightarrow$ 计划失配。**结果占位**: [LLMDIAG_BASELINE_TABLE]

5 正式实验计划 (待配置后执行)

(i) LLM 端: 提示模板 A/B (含/不含接地约束) $\times$ 模型规模, 评测忠实度增益; (ii) 反事实执行器跑通 top- k 干预重仿真 (每案例 3-5 次 episode, 分钟级); (iii) 案例集扩

至 200+ (覆盖 5 类 ground truth)。[LLM_RUN_PLACEHOLDER]

6 结论

本篇定义了引擎接地的调度诊断任务 (定位/归因/证据/干预四元组 + 反事实验证评测), 交付案例数据集构建器、规则基线与提示模板, LLM 推理与自我改进闭环列为下一步。代码见 `sky_research` 分支 `0901llmdiag`。

参考文献

- [1] Fei Liu et al. HeurAgenix: Leveraging LLMs for solving complex combinatorial optimization. *arXiv:2506.15196*, 2025.
- [2] Wenbin Zheng et al. CO-Bench: Benchmarking language model agents in algorithm search for combinatorial optimization. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2026.