

引擎接地的调度诊断解释层：LLM 在 FJSP+MAPF 耦合系统中的 定位、归因、可回查证据与可仿真干预

SkyResearch

2026 年 9 月 6 日 v2.3 草稿（四档模型主表含推理行 + hard 视图质检 + CF-INT 差距 + 反事实执行 + unseen 留出两档；agentic 与 frontier 待补）

When Do LLMs Fail at Engine-Grounded Scheduling Diagnosis?
Engine-Grounded Diagnosis with Executable Counterfactual Verification

摘要

FJSP+MAPF 耦合系统产生丰富的运行工件（指标轨迹、事件流、计划修订账本、异常日志），但缺少把它们变成可理解因果叙述的层。本文定义调度系统**事后诊断**任务 $\mathcal{D}: (\tau, q) \mapsto e$ ——给定运行档案 τ 与查询 q ，产出解释 $e = (\text{定位}, \text{归因}, \text{证据}, \text{干预})$ ，并给出使 LLM 输出可信的三重机制：（1）**注入式真值**——数据由引擎受控注入制造而非采集，标准答案零人工标注；（2）**可回查证据**——档案中每条事实带证据 ID，评分器逐条程序化核对；（3）**可仿真干预**——干预建议在引擎中以同种子反事实重仿真取得 ΔKPI ，LLM 不被允许“讲故事”。我们构建首个耦合调度诊断基准 cases_v2：随机化注入网格 + CRN 无故障孪生对照 + 涌现失效配方 + Generator-Executor-Verifier 核验闭环，52 个核验场景产出 104 个 easy/hard 孪生案例；核验器在首次实战中即拦截 26 个缺陷场景（含 13 个孪生暴露的混因配对）。规则基线在 easy/hard 孪生上的定位准确率 59.6% $\rightarrow$ 41.3%、JRA 59.6% $\rightarrow$ 34.6% 的塌陷证实了基准的区分力：无事件耦合失效（活锁/拥塞）构成对 LLM 泛化推断能力的受控测试。与 LLM-CO（HeurAgenix、CO-Bench 的生成侧）与在线决策（ReflecSched）不同，本层是事后诊断且可被引擎证伪。本文结论限于冻结参数、非 agentic、单轮打包设定下的本地模型（Qwen3-4B/8B/32B）；frontier、reasoning 与主动取证模型上的表现为开放问题。

1 引言

姊妹篇们把耦合系统当作被优化对象；本篇把它当作被解释对象。动机：车间运维面对的不是一个最优解，而是“为什么这批单晚了/为什么 AGV 都在等”——这需要把

指标轨迹、事件流与计划演变合成因果叙述。全文回答一个研究问题 (RQ1): **LLM 是在诊断调度失效, 还是只是在读显式的故障痕迹?** easy/hard 孪生 (§4) 与无事件涌现失效即为回答此问题而设计。

三个社区现状: (i) LLM-CO 用 LLM 生成启发式或搜算法 (FunSearch、EoH [1]、ReEvo [2]、HeurAgenix [3]、CO-Bench [4]), 属于生成侧, 无诊断视角; (ii) LLM 在线决策读轨迹提经验但服务于下一轮动作 (ReflecSched [5]), 评测其失败的是 DynaSched-Bench [6] ——但它诊断的对象是 LLM 调度器本身, 而非调度系统; (iii) AIOps 根因分析 (RCACopilot [7]、mABC [8]、ITBench [9]、Cloud-OpsBench [10]、OpenRCA [11]) 与我们的评测哲学最近——受控故障注入供 ground truth、agentic 工具取证——但其验证止步于人工标注与测试, 无重仿真量化, 也无跨层耦合失效。“LLM 输出的重仿真验证”最近的先例是数字孪生的实施前验证 [12] 与启发式优化的 matched-seeds 重仿真 [13], 二者对象均非诊断结论。

2 诊断任务形式化

定义 1 (轨迹). $\tau = (\mathbf{m}, \mathbf{e}, \mathbf{r}, \Sigma)$: 摘要 KPI 表 (20 项聚合指标)、事件样本 $\mathbf{e}$ 、计划修订账本 $\mathbf{r}$ 、配置 Σ 。

定义 2 (诊断). $\mathcal{D} : (\tau, q) \mapsto e$, 解释 $e = (\ell_t, \ell_r, h, V, \iota)$: 定位类型 ℓ_t 与目标 ℓ_r (双字段: $\ell_t \in \{\text{machine}, \text{agv}, \text{machine_agv}, \text{stochastic}, \text{task_pool}, \text{corridor}, \text{machines}, \text{none}\}$, ℓ_r 如 *machine:3*)、归因 h (8 类受控词表 + *unseen* 逃生舱)、证据 V (档案内带 ID 事实的引用集合)、干预 ι (引擎可执行配置词表: *padding/fleet/periodic_revision/assigner*)。

评测 (ground truth 来自受控注入):

$$\text{定位} = \Pr[\ell_t = \ell_t^* \wedge \ell_r = \ell_r^*] \text{ (仅类型对计 0.5)}, \quad \text{归因} = \Pr[h = h^*] \text{ (disruption 族宽容计 0.5)}, \quad (1)$$

$$\text{JRA} = \Pr[\text{定位满分} \wedge h = h^*], \quad \text{忠实度} = \frac{1}{|V|} \sum_{v \in V} \mathbb{I}[v \text{ 可回查}], \quad (2)$$

干预成功率 = $\Pr[\Delta \text{KPI}(\iota) \geq \delta]$ (同种子反事实重仿真)。忠实度在 statement 级执行: 除可回查外, 辅以对抗注入 (植入伪证据检验是否转引) 与证据消融 (删除被引证据检验结论是否漂移), 防止 post-rationalization [14]。干预成功率即**诊断效用** (Diagnostic Utility) $\mathcal{U} = \mathbb{E}[\Delta \text{KPI}(\pi(e))]$ 的经验估计——如同医学上的 *diagnosis* $\rightarrow$ *treatment* $\rightarrow$ *outcome*: 我们不问 “LLM 说得像不像专家”, 而问 “若按其解释施治, 系统能否被修复”。

3 架构

1. **证据打包器**: episode 记录 $\rightarrow$ 带证据 ID 的紧凑档案 (KPI:*/EVT001.../REV:*/CFG:*, $\leq 8k$ token; 剥离热力图)。每条事实可引用、可回查, 是忠实度可程序化核验的前

提。

2. **诊断策略**：同一数据底座、两种观测视图——(a) 单轮打包：档案整体入上下文，一次产出四元组（消融臂）；(b) *agentic* 工具层（设计中）：引擎暴露为查询工具（查 KPI/查事件/查修订/提交干预 → 触发反事实），主动取证（主系统）。2026 年的运维基准已明确批评单轮打包为 *passive classification* [10]，双层设计使我们无论何者胜出均有结论可写。输出经 *JsonRegen* 循环收口；答案期采样聚合。
3. **反事实执行器**：解析 ι → 修改配置 → 同种子重仿真 → ΔKPI 。采用公共随机数 (CRN) 配对差报告， ≥ 30 种子做 Wilcoxon 显著性 [15]；失败干预记 $\Delta KPI = -\infty$ 不丢弃。该判分器不依赖标签——词表外的新失效模式亦可评（忠实度 + ΔKPI + unseen 逃生舱）。
4. **训练阶梯**（评测框架的反哺）：frozen 提示 A/B → ReEvo 式反思精化（喂 best-so-far ΔKPI 对比证据）→ 反事实 DPO（同案例“有效/无效干预”构成偏好对，可验证奖励，无需人工标注）。

4 cases_v2: 注入式诊断基准

Generator–Executor–Verifier 闭环：场景生成器从网格抽样（实例 mk01–03 × 策略 × 车队 $K \in \{2, 3, 4, 6\}$ × 随机种子 × 随机化故障目标/时刻/时长），跑批器以进程隔离 + 硬超时执行，核验器按签名谓词判定——不达标即丢弃，宁可缺数不给错标签。

场景家族——按标签的认识论地位二分：注入式因果失效 (injected causal failures): $do(F=1)$ vs $do(F=0)$ ，标签由构造为真，CRN 孪生下是干净的干预效应；涌现式系统失效 (emergent systemic failures)：饥饿活锁、走廊拥塞等纯 FJSP/纯 MAPF 中不存在的耦合病理——没有任何显式故障事件，所有组件各自“正常”而组合死亡，标签由签名谓词定义（现象学诊断而非 $do()$ 意义上的根因），只有核验器确认签名后才入库。具体配方：(i) 注入故障 36（机器 16/双故障 12/随机扰动 8）；(ii) 基线 6；(iii) 涌现配方 8；(iv) **CRN 无故障孪生** 28：每个注入场景配同配置无故障孪生，孪生与故障案的 makespan 差即干预应恢复量；孪生未完工则配对作废。cases_v2 是该过程式生成器的一个抽样实例——基准以生成器的覆盖域与 held-out 泛化定义，规模可持续扩张。

核验器首次实战拦截 26 场景：13 个注入对因孪生未完工作废（greedy 臂在迷宫图系统性活锁——若无 CRN 孪生，这批案例将带混因标签入库）、5 个涌现配方签名未复现、1 对触发引擎接口屏障死循环（300s 硬超时拦截）。

5 实验：规则基线的 easy/hard 塌陷

规则基线（事件优先 + 阈值签名，v1 逻辑适配双字段）在 104 案例上：

归因类别	案例数 (easy+hard)	来源
baseline	34	基线 + 孪生
blocking_livelock	30	基线改标 (greedy 迷宫活锁, 签名确认)
disruption_machine	14	随机注入
disruption_machine_agv	10	随机双故障
starvation_livelock	8	涌现配方 (签名确认)
disruption_stochastic	8	preset (完工者保留)

表 1: cases_v2 构成: 52 个核验场景 $\times$ easy/hard 孪生 = 104 案例。easy 含事件流 (考阅读), hard 删除事件流只留统计特征 (考推断)。

变体	定位	归因 (严格)	JRA	解析率
easy (含事件流)	0.596	0.596	0.596	1.00
hard (无事件流)	0.413	0.481	0.346	1.00
首异常 (easy)	0.462	0.462	0.462	0.31
首异常 (hard)	0.327	0.327	0.327	0.00

表 2: 规则基线与首异常启发式 (G1.2 strawman) 的 easy/hard 对照。对比 v1 试点“95%/97.5%”的虚胖 (答案位于事件字段首行、故障目标恒为 0 号机), 随机化与无事件耦合失效构成实质难度。首异常启发式取最早事件实体作答: easy 档即低于规则 (“首个异常 $\neq$ 根因”: 涌现类无事件可考、随机扰动类归因缺位); 计划注入主事件之外的诱饵事件时间陷阱率为 0/12 (H5 预注册的诚实负结果); hard 档无事件流时全盲, 塌陷至 0.327。规则基线方向由一次独立实现交叉验证 (另一代码线 24 案例 greedy 单臂试点 easy $\rightarrow$ hard 定位 0.812 $\rightarrow$ 0.625, 与主表同向)。

塌陷幅度的含义: 规则只能回答预埋的签名, 无事件耦合失效上目标不可知 (部分分 0.5 封顶)。反事实推理文献预言 LLM 在 abduction 型任务上系统性弱 [16, 17]; 本基准给出首个调度域实证——结果如下。

全量结果给出五个发现: (F1) 非思考档内 hard 档 JRA 随规模 **单调降至零** (4B 0.038 $\rightarrow$ 8B 0.019 $\rightarrow$ 32B 0.000), easy 档非单调 (0.212 $\rightarrow$ 0.038 $\rightarrow$ 0.154) 且三档全部远低于规则的 0.596; 开启思考链的 30B MoE 是唯一在 hard 档取得两位数的 LLM (JRA 0.115, 为非思考档最高 0.038 的三倍) ——**思考链部分挽回溯因损失, 但仍低于规则基线的 0.346**; (F2) hard 档崩塌至接近零——无事件 abductive 推断的缺口在调度域被受控证实 (hard 视图三防线质检 52/52 通过, 塌陷非视图缺陷所致, 见 qc_hard_report.json); (F3) **忠实—正确分离**: 四档规模的忠实度均高达 0.95–1.00 且与正确率无关 (8B hard 定位全零、32B JRA 0.077 仍句句可回查) ——“引用成立 $\neq$ 诊断成立”的实测证据, 忠实度必须独立成指标; (F4) **基率忽视**: 4B 把 30/34 个无故障基线诊断为饥饿/拥塞/瓶颈, 8B 更甚 (29/33 判为 blocking), 32B 达到 34/34 全部误

诊断器	变体	定位	归因 (严格)	JRA	忠实度
规则	easy	0.596	0.596	0.596	–
规则	hard	0.413	0.481	0.346	–
Qwen3-4B (frozen)	easy	0.250	0.481	0.212	0.969
Qwen3-4B (frozen)	hard	0.087	0.308	0.038	0.990
Qwen3-8B (frozen)	easy	0.115	0.269	0.038	1.000
Qwen3-8B (frozen)	hard	0.000	0.269	0.019	0.990
Qwen3-32B (frozen)	easy	0.154	0.154	0.154	1.000
Qwen3-32B (frozen)	hard	0.067	0.000	0.000	1.000
Qwen3-30B-A3B (thinking)	easy	0.308	0.404	0.308	0.979
Qwen3-30B-A3B (thinking)	hard	0.173	0.327	0.115	0.949

表 3: cases_v2 主对照表 (104 案例, 温度 0, 干净档案视图)。4B/8B 经 Ollama 本地端点 (思考链无法关闭, 推理耗 3–5k token); 32B 经 vLLM 关闭思考链; 30B-A3B-Thinking 为推理模型 (思考链开启, reasoning parser 分离)。

诊, 30B-A3B-Thinking 同样 34/34 (28 判 blocking、6 判 starvation) ——四档模型都没有“正常运行包络”概念, 且不随规模与推理能力消失; (F5) **词表锚定失败**: 60 个走廊拥塞案例中 loc_type=“corridor”从未出现, 但 cause 判断部分正确 (4B 16/30、8B 14/30) ——知道病类、说不出病位; 32B 进一步出现**词表坍塌**: 88/104 收敛到单一标签 machine_bottleneck, 并产出词表外标签 disruption_agv (2 例)。干预药房约束四档模型均 100% 合规 (104 案例全部落在引擎可执行词表内; 30B-A3B-Thinking 90/104 选择同一干预 padding, 坍塌亦见于处方侧)。frontier 模型与 agentic 取证能否扭转 F1/F2 是本基准的开放问题。[LLM_SCALE_TABLE]

范围与局限: 本节结论的范围是冻结参数、单轮打包的本地 LLM (Qwen3 家族 4B/8B/32B 及 30B-A3B-Thinking 推理档)。三点须知: (i) 4B/8B 经 Ollama 端点、思考链无法关闭 (推理烧 3–5k token 后仍提取出最终答案); 32B 经 vLLM 以 enable_thinking=false 关闭思考链——规模轴上存在这一服务栈差异, 解释 32B easy 档相对 8B 的非单调回升时应计入; (ii) 全部为单轮打包诊断 (整个档案一次给出), 非 agentic 主动取证; (iii) 据此, 本文标题采取 “When Do LLMs Fail” 的条件式发问而非 “LLM 不能诊断” 的全称否定——frozen 小/中模型在本基准上的失败已实测, reasoning 与 agentic 是否翻案待 §5.2 的工具层与 frontier 行回答。

5.1 CF–INT: 塌陷的信息归因

为区分 hard 档塌陷是“信息不足”还是“溯因无能”, 为 16 个注入场景生成 INT 视图 (hard + **公开注入参数**, 即 v0.2 防线 3 的兜底归因)。Qwen3-32B 在 INT 档整体 JRA 回升至 0.75 (hard: 0.000), 分解如下:

归因类	hard JRA	INT JRA	差距
disruption_machine	0.5	1.0	+0.5
disruption_machine_agv	0.1	1.0	+0.9
disruption_stochastic	0.0	0.0	0

表 4: CF-INT 差距 (Qwen3-32B, 注入类)。

两点结论: (i) 防线 2 标记的混淆对 (machine_agv $\times$ stochastic, hard 视图标记轮廓重合 1.0) 被公开注入参数**完全消解** (0.1 $\rightarrow$ 1.0) ——**塌陷是信息不对称而非模型无能**, 与 F2/F3 共同构成“观测形态决定诊断上界”的证据链; (ii) preset 型故障 (stochastic) INT 仍为 0——其公开参数只有 preset 名与种子, 无具体时刻/目标可公开, INT 消歧对概率型故障天然失效 (该类需要公开注入事件时间戳, 留作 v2.2)。

5.2 反事实执行与 unseen 留出

反事实执行器 (药房词表 $\rightarrow$ 配置增量 $\rightarrow$ 同 seed 重仿真 $\rightarrow$ Δ KPI, 对齐 CRN 孪生的应恢复量) 在规则臂 9 例上: 6 例有效 (成功率 0.667; 最佳 padding/fleet Δ KPI +99/+375), 1 例有害 (Δ KPI -67) ——“无效干预率”开始区分“敢开方”与“开对方”。同 seed 重仿真本身获得**逐位复现实证** (重跑 makespan 与入库值一致), CRN 判分的确定性假设成立。LLM 臂 (32B 与 30B-A3B-Thinking, n=133 重仿真) 干预成功率 0.31-0.32 (规则臂 0.667); greedy/涌现臂近乎全灭 (0-7

unseen 留出 (leave-one-class-out, Patch B): 先后把 starvation_livelock 与 blocking_livelock 从归因词表抽走, Qwen3-32B 两档轮换完全一致——诚实率 **0.0**、沉默失败率 **1.0**、假阳性率 **0.0**: 模型从不使用 unseen 逃生舱承认不认识 (词表坍缩支配一切), 但也不滥用逃生舱。其余类别轮换与干预有效性维度进行中。

测量有效性: 开发过程曾因 ground_truth 随档案整体进入 prompt 而得到 100% 的虚假满分 (该全量结果作废留档)。此后诊断器只允许经 model_view() 白名单取档案本体, 并确立纪律: 异常好的分数先疑测量、再疑模型。该事故与处置作为基准工程的一部分一并公开。

6 结论

本文定义了引擎接地的调度诊断任务 (双字段定位/归因/证据/干预 + 三层判分 + 反事实验证), 交付 Generator-Executor-Verifier 式基准 cases_v2 (104 案例, 核验闭环拦截 26 缺陷场景) 与首个 easy/hard 塌陷基线。四档 LLM (含推理档) 全量评测、反事实执行器与 unseen 留出已完成; agentic 工具层、KPI 时序统计基线与 frontier 行为下一步; 训练阶梯 (反思精化、反事实 DPO) 以本框架的可验证奖励为基础。代码与数据见 sky_research 分支 0901llmdiag。

参考文献

- [1] Fei et al. Evolution of Heuristics: Towards Efficient Automatic Algorithm Design Using Large Language Model. arXiv:2401.02051, 2024.
- [2] Ye et al. ReEvo: Large Language Models as Hyper-Heuristics with Reflection. NeurIPS, arXiv:2402.01145, 2024.
- [3] HeurAgenix: Evolving Heuristics via LLMs. arXiv:2506.15196, 2025.
- [4] CO-Bench: Benchmarking LLM Agents on Combinatorial Optimization. AAAI, arXiv:2504.04310, 2026.
- [5] ReflecSched: LLM Agents for Dynamic Flexible Job Shop Scheduling. arXiv:2508.01724, 2025.
- [6] DynaSchedBench: Dynamic Scheduling LLM Agent Benchmark. ICML, arXiv:2605.27566, 2026.
- [7] Chen et al. Automatic Root Cause Analysis via LLMs for Cloud Incidents. EuroSys, arXiv:2305.15778, 2023.
- [8] mABC: Multi-Agent Blockchain-Inspired Collaboration for Root Cause Analysis. EMNLP Findings, arXiv:2404.12135, 2024.
- [9] ITBench: Benchmarking Agentic AI for IT Operations. ICML, arXiv:2502.05352, 2025.
- [10] Cloud-OpsBench: Agentic Cloud Operations RCA Benchmark. arXiv:2603.00468, 2026.
- [11] OpenRCA 2.0: From Outcome Labels to Causal Process Supervision. arXiv:2606.27154, 2026.
- [12] LLM Agents with Digital Twins for Process Fault Handling. IEEE ETFA, arXiv:2505.02076, 2025.
- [13] LLM-Guided Heuristic Design from Simulation Traces. arXiv:2608.09343, 2026.
- [14] Wallat et al. Correctness is not Faithfulness in RAG Attributions. SIGIR, arXiv:2412.18004, 2024.
- [15] Klein et al. Noise-free comparison of stochastic agent-based simulations using common random numbers. arXiv:2409.02086, 2024.
- [16] CounterBench: Benchmarking Causal Counterfactual Reasoning in LLMs. arXiv:2502.11008, 2025.
- [17] Executable Counterfactuals: abduction steps in counterfactual benchmarks. arXiv:2510.01539, 2025.